

Detecção de Tráfego Malicioso em Redes Corporativas

Victor S. Hong, Mauricio C. Vicentini, Lucas Crepalde, Rafael Riki, Henrique Higa

¹Faculdade de Computação e Informação – Universidade Presbiteriana Mackenzie
(UPM)
São Paulo – SP – Brazil

Resumo. *Este artigo apresenta uma abordagem de Inteligência Artificial para aprimorar a segurança de redes corporativas por meio da identificação de tráfego malicioso. Ferramentas tradicionais baseiam-se em regras estáticas, frequentemente insuficientes contra novas ameaças. Utilizando o dataset UNSW-NB15, propomos o desenvolvimento e a avaliação de modelos de classificação por aprendizado supervisionado. Ademais, técnicas de IA Explicável (XAI) serão aplicadas para fornecer transparência ao processo decisório, reduzindo falsos positivos e melhorando a eficiência das equipes de Segurança da Informação.*

1. Introdução

1.1. Contextualização

As redes de computadores sofrem ataques constantes que tentam derrubar servidores, roubar informações ou invadir sistemas corporativos. Atualmente, as ferramentas tradicionais de segurança da informação, como firewalls e sistemas de detecção de intrusão convencionais, dependem de regras fixas (assinaturas) que muitas vezes não conseguem identificar formas inéditas de ataque. O uso de técnicas de Inteligência Artificial (IA) surge como uma solução para analisar os registros de tráfego de rede de forma automática, reconhecendo padrões e comportamentos suspeitos em tempo real.

1.2. Justificativa

Os dados de tráfego de rede são, por natureza, registros numéricos e categóricos altamente estruturados, compreendendo informações como duração da conexão, volume de dados, protocolos e portas utilizadas. O aprendizado supervisionado de classificação e a detecção de anomalias são as técnicas ideais para esse formato de dado, pois conseguem processar altos volumes de informações com rapidez e alta precisão. Além disso, a aplicação de IA Explicável (XAI) é fundamental para que o motivo do alerta gerado pelo modelo possa ser auditado e compreendido pelas equipes que gerenciam a infraestrutura de rede.

1.3. Motivação

Detectar ameaças rapidamente é um requisito crítico para garantir a continuidade operacional, evitando que sistemas saiam do ar ou sofram vazamentos de dados sensíveis. Simultaneamente, um modelo de IA bem ajustado ajuda a diminuir drasticamente a taxa de falsos positivos, o que evita o desperdício de tempo e recursos das equipes de TI e Segurança da Informação, tornando a proteção da rede mais ágil, escalável e eficiente.

1.4. Objetivo

O objetivo deste projeto é construir e avaliar modelos de classificação capazes de analisar dados de tráfego de rede e identificar automaticamente se uma conexão é legítima ou consiste em um ataque malicioso. O projeto visa também explicar quais características do tráfego foram mais importantes para essa decisão, utilizando técnicas de interpretabilidade.

1.5. Contribuições Esperadas

As principais contribuições deste projeto englobam: o mapeamento da segurança de tráfego como uma tarefa formal de classificação; a limpeza e preparação de uma base pública; o treinamento e comparação de modelos clássicos (como Árvores de Decisão e Random Forest); a medição do desempenho com métricas padrão (Acurácia, Precisão, Recall e F1-Score); a aplicação de interpretabilidade para justificar as decisões do modelo; e a entrega de um repositório organizado e reproduzível contendo todo o ciclo de vida do experimento.

2. Conceitos Fundamentais

2.1. Conceitos Fundamentais

O projeto fundamenta-se no Aprendizado de Máquina Supervisionado, especificamente em tarefas de classificação, onde o algoritmo aprende a mapear entradas (características do pacote de rede) para saídas rotuladas (tráfego normal ou malicioso). O uso de modelos baseados em árvores, como Random Forest, é comum devido à sua capacidade de lidar com dados tabulares complexos e não-lineares. Além da classificação pura, a Detecção de Anomalias serve como paradigma para identificar desvios críticos do comportamento padrão da rede.

Outro pilar técnico é a Inteligência Artificial Explicável (XAI). Em cibersegurança, modelos do tipo "caixa-preta" apresentam baixa adoção. O uso da explicabilidade garantirá transparência às instituições, alinhando-se diretamente ao ODS 9 (fortalecimento de infraestruturas resilientes) e ao ODS 16 (desenvolvimento de instituições transparentes e seguras contra atores maliciosos).

2.2. Trabalhos Relacionados

A detecção de intrusões (IDS) utilizando aprendizado de máquina tem sido amplamente estudada. Trabalhos seminais na área demonstram que algoritmos tradicionais superam sistemas baseados em regras na detecção de ataques do tipo Zero-Day. Pesquisadores que introduziram o dataset UNSW-NB15 destacaram que bases mais antigas, como a KDD99, já não refletem a topologia moderna de ameaças. As soluções da literatura frequentemente utilizam redes neurais profundas e *Ensemble Learning* para maximizar o *Recall* em ataques de negação de serviço (DoS) e reconhecimento, servindo como base comparativa para os resultados que serão obtidos neste projeto.

3. Metodologia e Resultados Esperados

3.1. Abordagem Metodológica

A metodologia deste projeto baseia-se em um pipeline padrão de Ciência de Dados para IA. As etapas incluem: (1) coleta dos dados brutos; (2) análise exploratória para compreender a distribuição das classes (ataques vs. tráfego normal) e a correlação entre as variáveis de rede; (3) pré-processamento, incluindo normalização de valores contínuos e codificação de variáveis categóricas (como protocolos TCP/UDP); (4) separação dos dados em conjuntos de treino e teste; (5) treinamento de modelos supervisionados; e (6) avaliação baseada em métricas de classificação.

3.2. Dataset e Preparação dos Dados

O projeto utiliza o dataset público UNSW-NB15, obtido através da plataforma Kaggle. Esta base contém registros estruturados de tráfego de rede gerados em um laboratório de cibersegurança, abrangendo tráfego normal e diversas famílias de ataques sintéticos. Durante a etapa de preparação, realiza-se o tratamento de valores nulos, a remoção de *features* redundantes identificadas na análise de correlação e o balanceamento das classes, visto que ataques tendem a ser a minoria em relação ao tráfego corporativo legítimo.

3.3. Resultados Esperados

Espera-se desenvolver um modelo capaz de distinguir tráfego anômalo com alto F1-Score, demonstrando capacidade de generalização e baixo índice de falsos positivos. Ademais, espera-se que o módulo de explicabilidade destaque atributos como contagem de pacotes, bytes transferidos e taxas de erro TCP como fatores determinantes na predição.

4. Resultados Parciais

4.1. Aspectos Éticos e Responsabilidade no uso da IA

A aplicação de IA na segurança cibernética levanta questões éticas cruciais. Primeiramente, falsos positivos em um modelo de classificação podem bloquear o acesso de usuários legítimos a recursos críticos de rede (negação de serviço não intencional). Em segundo lugar, o treinamento de IA em dados de rede levanta questões sobre a privacidade dos dados trafegados, exigindo que pacotes sejam anonimizados antes da extração de *features*. A responsabilidade no desenvolvimento exige o uso de XAI para garantir que alertas não se baseiem em vieses sistêmicos, garantindo total transparência e auditoria das ações defensivas.

4.2. Resultados Obtidos (Análise Exploratória)

A análise exploratória do dataset de 175.341 registros e 36 colunas revelou que 68,1% das amostras representam ataques cibernéticos, com maior incidência nas categorias "Generic", "Exploits" e "Fuzzers", enquanto 31,9% consistem em tráfego normal. A matriz de correlação apontou forte redundância (valores $> 0,95$) entre as variáveis de contagem de pacotes (spkts, dpkts), volume de bytes (sbytes, dbytes) e perda de pacotes (sloss, dloss), indicando oportunidade para redução de dimensionalidade. Por fim, observou-se que a classificação de tráfego malicioso (label) possui correlação positiva com a taxa de transferência (rate) e correlação negativa com a carga de destino (dload).




Figura 1. Distribuição da variável alvo (0 = Normal, 1 = Malicioso).




Figura 2. Volume de conexões por categoria de ataque cibernético.




Figura 3. Matriz de correlação linear das características de rede selecionadas.

4.3. Repositório do Projeto O código-fonte da análise exploratória, o dataset com suas respectivas descrições e o histórico de evolução encontram-se documentados e públicos no repositório do projeto:

Link: <https://github.com/VSWH/IDS.git>

5. Referências

Moustafa, N. and Slay, J. (2015). "UNSW-NB15: a comprehensive data set for network intrusion detection systems". In *Military Communications and Information Systems Conference (MilCIS)*, IEEE, p. 1-6.

Kaggle (2024). "UNSW-NB15 Network Intrusion Detection Dataset". Disponível em: <https://www.kaggle.com/datasets/dhoogla/unswnb15>. Acesso em: 24 set. 2026.